

Auditoría de calidad de datos y modelos lineales de referencia para la predicción de fuga de clientes en una fintech colombiana: detección y cuantificación de fuga de información

Valerie Martínez Pulido · Abrahan Basto Martínez · Rubén Esguerra Fernández

Departamento de Matemáticas, Física y Ciencia de Datos, Universidad del Norte, Barranquilla, Colombia

pmartinezv@uninorte.edu.co · abrahamb@uninorte.edu.co · esguerrar@uninorte.edu.co

Curso de Machine Learning — Entrega 2: Preparación de datos y modelos base

Resumen

La predicción de la fuga de clientes es una tarea central en los servicios financieros minoristas, y su resolución mediante aprendizaje supervisado depende críticamente de la calidad de los datos de entrada. En este trabajo se presentan la auditoría de datos y los modelos base de un proyecto sobre un conjunto público de una empresa fintech colombiana correspondiente a 2023, compuesto por 48.723 clientes descritos con 54 variables y 3.159.157 transacciones individuales. El análisis exploratorio identificó tres problemas con impacto directo sobre el modelado: la variable objetivo resultó casi determinada por el número de productos activos, con una escalera de paso exactamente constante de 0,05 que explica el 76,7 % de su varianza; tres columnas transaccionales resultaron duplicados desalineados o exactos; y los valores faltantes de la utilización de crédito resultaron estrictamente estructurales. Como consecuencia se eliminaron diecisiete variables, cada una respaldada por evidencia cuantitativa. Dado que la variable objetivo es continua, se abordan las dos formulaciones: regresión sobre el puntaje y clasificación tras binarizarlo. Un experimento de ablación cuantifica la fuga de información en ambas, y es la formulación de regresión la que lo hace con más nitidez: incluir la variable sospechosa eleva el coeficiente de determinación de 0,151 a 0,921, y el área bajo la curva de 0,682 a 0,974. Sobre el conjunto depurado, una regresión logística con penalización L_1 alcanza un área bajo la curva de 0,683 en prueba, con exhaustividad de 0,652, seleccionando cincuenta y siete de setenta y ocho variables; una regresión Lasso sobre el objetivo continuo alcanza $R^2 = 0,151$ con cuarenta variables. Un clasificador de k vecinos más cercanos, que no impone forma funcional alguna, no supera al modelo lineal, lo que acota empíricamente el margen de mejora disponible. El desempeño se concentra en tres predictores, mientras que el comportamiento transaccional no aporta capacidad predictiva alguna.

Palabras clave: Fuga de clientes, Regresión logística, Regresión Ridge y Lasso, Fuga de información, Calidad de datos, Fintech.

1 Introducción

La retención de clientes y la estimación de su valor son dos problemas centrales en la banca minorista y en el sector *fintech*. Adquirir un cliente nuevo resulta considerablemente más costoso que conservar uno existente, y el aporte económico de cada cliente a lo largo de su relación con la entidad es marcadamente heterogéneo, por lo que anticipar quién tiene mayor probabilidad de fuga (*churn*) y cuánto valor generará (*customer lifetime value*, CLV) permite focalizar las acciones comerciales donde tienen mayor impacto (Gupta et al., 2006; Verbeke et al., 2012). Ambas tareas se abordan habitualmente como problemas de aprendizaje supervisado: clasificación o regresión para la fuga, y regresión —o clasificación ordinal sobre segmentos de valor— para el CLV.

Sobre datos tabulares como los de este dominio, los modelos de referencia van desde alternativas lineales interpretables, como la regresión logística y las regresiones regularizadas Ridge y Lasso, hasta métodos de ensamble que constituyen el estándar actual, como Random Forest (Breiman, 2001) y XGBoost (Chen y Guestrin, 2016). Estos algoritmos son robustos frente a variables heterogéneas y relaciones no lineales, y por ello son la elección natural para el modelado posterior de este proyecto. Sin embargo, su desempeño está condicionado por un factor previo a la elección del algoritmo: la calidad y la coherencia de los datos de entrada. Metodologías clásicas del área, como CRISP-DM (Wirth y Hipp, 2000), sitúan precisamente las fases de comprensión y preparación de los datos antes del modelado, y el análisis exploratorio de datos (EDA) en el sentido de Tukey (1977) es la herramienta para ejecutarlas.

Una limitación frecuente y a menudo subestimada en esta fase es la fuga de información (*data leakage*): cuando una variable predictora codifica, de forma directa o indirecta, la información de la etiqueta, las métricas de validación se inflan artificialmente y el modelo no generaliza a datos nuevos (Kaufman et al., 2012). La fuga no se limita a las variables: también puede introducirse en el propio procedimiento experimental, cuando un estadístico estimado sobre la totalidad de los datos —un umbral, una media de escalado, los niveles de una codificación— se emplea antes de separar el conjunto de prueba. A ello se suman problemas de calidad más prosaicos pero igualmente dañinos: columnas duplicadas o desalineadas que introducen multicolinealidad y ruido, y un tratamiento inadecuado de los valores faltantes, cuyo mecanismo generador —aleatorio o estructural— determina si imputar es legítimo o si equivale a inventar información (Little y Rubin, 2019). Detectar estas condiciones antes de entrenar es, por tanto, tan determinante para el resultado final como la selección del modelo.

En este trabajo se aborda la fase de comprensión y preparación de datos de un proyecto de modelado sobre un conjunto público de clientes de una empresa fintech colombiana correspondiente al año 2023 (Muñoz Guerrero et al., 2025), compuesto por 48.723 clientes descritos con 54 variables y 3.159.157 transacciones individuales, cuyas variables objetivo candidatas son la probabilidad de fuga (*churn_probability*) y el valor del cliente (*customer_lifetime_value* y su versión categórica *clv_segment*). El objetivo es doble: caracterizar el conjunto mediante un análisis exploratorio exhaustivo y auditar su calidad para definir un preprocesamiento riguroso y reproducible.

La contribución de esta entrega es la identificación cuantitativa de tres problemas con impacto directo sobre el modelado —una fuga de información en la etiqueta de *churn*, un grupo de columnas transaccionales duplicadas y desalineadas, y valores faltantes de naturaleza estructural— y la definición, como consecuencia directa de dichos hallazgos, de un conjunto de datos depurado y un plan de preprocesamiento. Sostenemos que, sin esta auditoría previa, un modelo entrenado sobre los datos crudos alcanzaría un desempeño engañosamente alto, por la relación casi determinista entre la fuga y el número de productos activos, y arrastraría redundancia evitable; y mostramos con evidencia empírica las correcciones necesarias antes de la fase de modelado.

2 Metodología

2.1 Descripción del problema y del conjunto de datos

(1) Descripción general

El conjunto de datos empleado es COFINFAD: *Colombian Fintech Financial Analytics Dataset*, publicado de forma abierta en el repositorio Mendeley Data bajo licencia Creative Commons Attribution 4.0 (Muñoz Guerrero et al., 2025). Corresponde a clientes de una empresa fintech colombiana durante los doce meses del año 2023 y

se distribuye en dos archivos complementarios. La versión utilizada en este trabajo contiene 54 de las variables documentadas en el repositorio. El primero, `customer_data.csv`, contiene un registro por cliente: 48.723 filas y 54 columnas que combinan perfil demográfico, tenencia de productos, uso de canales digitales, satisfacción y NPS, resúmenes de actividad transaccional y las variables objetivo. El segundo, `transactions_data.csv`, contiene el detalle individual de 3.159.157 transacciones con cuatro campos: `customer_id`, `date`, `amount` y `type`. La Tabla 1 resume la composición de la tabla de clientes por tipo de variable.

Tabla 1: Composición de la tabla de clientes por tipo de variable.

Tipo	Ejemplos	Cantidad
Númericas	age, active_products, churn_probability	28
Catóricas	gender, location, income_bracket	13
Booleanas	savings_account, credit_card	7
Fecha	first_transaction_date, last_survey_date	5
Identificador	customer_id	1
Total		54

Se consideran dos variables objetivo. La primera, `churn_probability`, es una variable continua acotada al intervalo $[0,11; 0,50]$ con media 0,343, susceptible de tratarse como regresión o, tras binarizarla por un umbral, como clasificación. En esta entrega se desarrollan **ambas formulaciones**, por dos razones: porque la variable disponible es continua y binarizarla descarta información, y porque el contraste entre las dos permite diagnosticar la fuga de información con mucha mayor precisión, como se muestra en la Sección 3.1. La segunda, `customer_lifetime_value`, es continua, fuertemente asimétrica (mediana $\approx 1,30 \times 10^8$ frente a media $\approx 3,28 \times 10^8$ COP) y cuenta con una versión catórica ordinal, `clv_segment`, con cuatro niveles (*Bronze*, *Silver*, *Gold*, *Platinum*); el nivel más frecuente es *Bronze*, con 12.181 clientes (25,0 %), por lo que el balance entre segmentos es aproximadamente uniforme. Todos los clientes de la tabla poseen actividad transaccional registrada.

(2) ETL (Extract, Transform, Load)

Extract. Los datos se obtuvieron en formato CSV desde el repositorio público. La tabla de clientes se carga directamente y la de transacciones se lee interpretando el campo `date` como tipo fecha, lo que habilita la agregación temporal posterior. Ambos archivos se leen con `pandas` en Python 3. La ruta se resuelve de forma relativa al cuaderno, de modo que la ejecución no depende de la máquina.

Transform. Las decisiones de limpieza no son *a priori*: se derivan de los hallazgos del EDA descritos en la Sección 2.2. En síntesis: (i) no se eliminan filas por duplicación en la tabla de clientes, pues no existen registros ni identificadores repetidos, mientras que en la tabla de transacciones se detectaron 102 filas exactamente duplicadas (0,003 % del total), volumen despreciable que se elimina por consistencia; (ii) se descartan las columnas transaccionales identificadas como duplicados desalineados o redundantes, conservando sus equivalentes verificadas contra el detalle de transacciones; (iii) los valores faltantes no se imputan con medidas de tendencia central: en la utilización de crédito se imputa cero por tratarse de un faltante estructural, y las columnas cuya ausencia no muestra mecanismo ni señal se descartan; (iv) los valores atípicos de las variables monetarias no se eliminan, ya que corresponden a colas legítimas.

Load. El resultado es un conjunto depurado de 48.723 filas y 49 columnas que se serializa junto con la partición empleada, de modo que la siguiente entrega parta exactamente del mismo material.

(3) EDA exhaustivo

Por su extensión, el análisis exploratorio de datos —tercera componente de esta subsección— se desarrolla de forma independiente en la Sección 2.2.

2.2 Análisis exploratorio de datos

Esta sección desarrolla el análisis exploratorio exhaustivo correspondiente a la componente (3) de la Sección 2.1. Se organiza en estadística descriptiva, análisis univariado, análisis bivariado y de correlación, detección de atípicos, auditoría de calidad y comportamiento transaccional, y cierra con las decisiones de preprocesamiento que se derivan directamente de lo observado.

2.2.1 Estadística descriptiva

La Tabla 2 presenta los estadísticos de las variables numéricas más relevantes. Se observan tres comportamientos distintos: variables acotadas en rangos estrechos (edad, antigüedad), variables de escala monetaria con dispersión extrema (volumen y valor de transacción, CLV) y variables de satisfacción concentradas en pocos valores.

Tabla 2: Estadísticos descriptivos de variables numéricas seleccionadas ($n = 48.723$).

Variable	Media	Desv. est.	Mín.	Mediana	Máx.
age	44,54	12,28	29,00	45,00	60,00
household_size	3,50	1,58	1,00	3,00	13,00
active_products	2,10	1,18	1,00	2,00	5,00
app_logins_frequency	22,38	11,75	4,00	22,00	100,00
satisfaction_score	4,16	0,58	2,00	4,00	6,00
nps_score	-26,76	12,56	-80,00	-28,00	23,00
customer_tenure	11,37	0,72	4,70	11,63	11,97
tx_count	64,84	611,93	10,00	18,00	77.465,00
avg_tx_value	$3,56 \times 10^6$	$3,96 \times 10^6$	$3,18 \times 10^5$	$1,76 \times 10^6$	$5,17 \times 10^7$
total_tx_volume	$2,57 \times 10^8$	$6,21 \times 10^9$	$3,18 \times 10^6$	$4,81 \times 10^7$	$1,07 \times 10^{12}$
churn_probability	0,343	0,07	0,11	0,35	0,50
customer_lifetime_value	$3,28 \times 10^8$	$7,93 \times 10^8$	0,00	$1,30 \times 10^8$	$1,78 \times 10^{10}$

La distancia entre media y mediana en las variables monetarias —en `total_tx_volume` la media quintuplica a la mediana— anticipa la fuerte asimetría a la derecha que se confirma en el análisis univariado. En sentido contrario, `customer_tenure` presenta una desviación estándar de apenas 0,72 sobre un máximo de 11,97, indicando una concentración casi total de los clientes en el mismo rango de antigüedad.

2.2.2 Análisis univariado

La Figura 1 presenta la distribución de las principales variables numéricas. Las variables monetarias exhiben colas largas hacia la derecha que comprimen la mayor parte de la masa de probabilidad contra el eje; por ello la Figura 2 las reexpresa en escala logarítmica mediante diagramas de caja, donde su estructura y su dispersión resultan legibles.

Distribuciones — variables numericas




Fig. 1: Distribución de las principales variables numéricas de la tabla de clientes.




Fig. 2: Variables monetarias en escala logarítmica $\log(1 + x)$. La longitud de los bigotes evidencia la asimetría remanente incluso tras la transformación.

La distribución de *churn_probability* (Figura 9, izquierda) es unimodal y aproximadamente simétrica en torno a 0,35, pero truncada en ambos extremos: no existen clientes con probabilidad inferior a 0,11 ni superior a 0,50. Esta ausencia de valores en las regiones extremas es la primera señal de que la variable no registra un evento de fuga observado, sino un puntaje previamente calculado. El CLV (Figura 12, izquierda), en escala logarítmica, se aproxima a una distribución normal, comportamiento característico de las variables log-normales propias de magnitudes monetarias.

Respecto de las variables categóricas (Figura 3), el género se reparte de forma casi equilibrada (24.033 mujeres, 49,3 %) y el sentimiento del *feedback* es mayoritariamente positivo (38.897 clientes, 79,8 %). Entre las variables de alta cardinalidad (Figuras 4 y 5), Bogotá concentra 16.967 clientes (34,8 %), mientras que *occupation* distribuye 48.723 clientes entre 35 niveles con una frecuencia máxima de apenas 1.456 casos (3,0 %), lo que la convierte en una variable de escaso poder discriminativo en su forma actual.




Fig. 3: Frecuencias de las variables categóricas de baja cardinalidad.




Fig. 4: Quince ocupaciones más frecuentes. La frecuencia máxima no alcanza el 3 % del total.




Fig. 5: Quince ubicaciones más frecuentes, encabezadas por Bogotá con el 34,8 % de los clientes.

La tenencia de productos (Figura 6) es marcadamente desigual: la cuenta de ahorros alcanza al 78,9 % de los clientes y el pago de facturas al 70,1 %, mientras que el producto de seguros solo llega al 21,2 %. Esta variable resultará central en el análisis de la fuga.




Fig. 6: Tasa de tenencia o adopción por producto financiero.

2.2.3 Valores faltantes y su mecanismo

Los valores ausentes se concentran en únicamente tres columnas (Figura 7 y Tabla 3); las 51 restantes están completas.




Fig. 7: Porcentaje de valores faltantes por columna. Solo tres variables presentan ausencias.

Tabla 3: Columnas con valores faltantes y mecanismo identificado.

Columna	Faltantes	%	Mecanismo
complaint_topics	24.346	50,0	No explicado por las variables examinadas
credit_utilization_ratio	18.263	37,5	Estructural: ausente si no posee tarjeta
feature_requests	16.115	33,1	No explicado por las variables examinadas

El contraste de cada columna contra una variable que pudiera explicar la ausencia arroja un resultado concluyente para `credit_utilization_ratio`: la tabla de contingencia frente a `credit_card` es perfecta, ya que el 100 % de los registros con valor ausente corresponde a clientes sin tarjeta de crédito y el 100 % de los registros informados corresponde a clientes con tarjeta. Se trata, por tanto, de un faltante estrictamente estructural, cuyo significado es *no aplica* y no *dato perdido*. En cambio, `complaint_topics` y `feature_requests` no muestran relación con las variables de referencia examinadas, por lo que su ausencia se comporta como aproximadamente aleatoria; su correlación con la variable objetivo es de $-0,0007$ y $-0,0066$ respectivamente. Esta distinción es relevante porque implica tratamientos diferentes: imputar cero en la utilización de crédito es correcto por definición del dominio, mientras que para las otras dos columnas la decisión defendible es descartarlas y evitar imputaciones sin respaldo en los datos.

2.2.4 Auditoría de columnas transaccionales redundantes

El conjunto incluye dos grupos de columnas que resumen la actividad transaccional de cada cliente. Una comparación directa muestra que ninguno de los tres pares principales coincide fila a fila, resultado que en principio sugeriría que miden magnitudes distintas. Sin embargo, al comparar además sus distribuciones como conjuntos de valores ordenados, el diagnóstico cambia por completo (Tabla 4).

Tabla 4: Diagnóstico de los pares de columnas transaccionales. La columna *mismos valores* compara ambas series tras ordenarlas.

Par de columnas	Coinciden por fila (%)	Mismos valores (%)	Diagnóstico
avg_tx_value / average_transaction_value	0,0	100,0	Duplicado desalineado
total_tx_volume / total_transaction_volume	0,0	100,0	Duplicado desalineado
tx_count / monthly_transaction_count	0,0	0,0	Distinta ventana temporal
transaction_frequency / avg_daily_transactions	100,0	100,0	Duplicado exacto

Los dos primeros pares contienen exactamente el mismo conjunto de valores —coincidencia del 100 % al ordenarlos— pero ninguna correspondencia a nivel de fila. La única explicación consistente con ambos hechos es que se trata de la misma variable cuyo orden fue alterado respecto de los identificadores de cliente: un duplicado corrupto, no una medida alternativa. El cuarto par es un duplicado exacto y alineado, redundante por definición. El tercero, en cambio, corresponde a la misma magnitud expresada en una ventana temporal distinta. Este diagnóstico se verifica de forma independiente en la Sección 2.2.10 contra el detalle real de transacciones.

Consistentemente, el análisis de multicolinealidad (Tabla 5) identifica un bloque de tres variables mutuamente idénticas y un par de variables de satisfacción fuertemente asociadas.

Tabla 5: Pares de variables numéricas con correlación $|r| > 0,9$.

Variable A	Variable B	<i>r</i>
transaction_frequency	avg_daily_transactions	1,000
monthly_transaction_count	avg_daily_transactions	1,000
monthly_transaction_count	transaction_frequency	1,000
satisfaction_score	nps_score	0,917

2.2.5 Rangos acotados

Varias variables presentan límites que resultan difíciles de atribuir a un proceso natural de registro (Tabla 6).

Tabla 6: Rangos observados en variables con acotamiento sospechoso.

Variable	Mín.	P1	P99	Máx.
age	29,00	29,00	60,00	60,00
churn_probability	0,11	0,17	0,46	0,50
customer_tenure	4,70	8,63	11,97	11,97
satisfaction_score	2,00	3,00	5,00	6,00

La edad se restringe exactamente al intervalo de 29 a 60 años, sin un solo cliente fuera de él, y la antigüedad se satura en 11,97 tanto en el percentil 99 como en el máximo. Que una probabilidad no alcance nunca los extremos 0 y 1 refuerza la interpretación de churn_probability como un puntaje derivado. En conjunto, estos patrones sugieren que el conjunto es al menos parcialmente sintético, lo que obliga a ser prudente al extrapolar conclusiones fuera de los rangos observados. Finalmente, se registra un único cliente con CLV exactamente igual a cero (0,002 % del total), volumen irrelevante que no compromete el análisis.

2.2.6 Valores atípicos

La cuantificación mediante la regla del rango intercuartílico con factor 1,5 (Tabla 7) confirma lo anticipado por los diagramas de caja.

Tabla 7: Variables con mayor proporción de valores atípicos (regla IQR 1,5×).

Variable	Atípicos	%
failed_transactions	8.818	18,1
monthly_transaction_count	6.394	13,1
transaction_frequency	5.889	12,1
avg_daily_transactions	5.889	12,1
tx_satisfaction	5.783	11,9
tx_count	5.783	11,9

Estos valores no corresponden a errores de captura sino a colas legítimas de distribuciones asimétricas: en `failed_transactions`, por ejemplo, la mediana y ambos cuartiles valen cero, de modo que cualquier cliente con al menos una transacción fallida es marcado como atípico por construcción de la regla. Eliminar estas observaciones supondría descartar precisamente a los clientes más activos y a los que experimentan incidencias, que son informativos para ambos objetivos. La decisión adoptada es conservarlos.

2.2.7 Análisis bivariado y de correlación

La matriz de correlación de Pearson (Figura 8) resume las asociaciones lineales entre las 28 variables numéricas. Destacan tanto los bloques de variables transaccionales mutuamente redundantes ya identificados como una asociación aislada y muy intensa con la variable objetivo de fuga.




Fig. 8: Matriz de correlación de Pearson de las variables numéricas.

Dado el fuerte sesgo de las variables monetarias, la Tabla 8 contrasta el coeficiente de Pearson con el de Spearman, que captura relaciones monótonas no necesariamente lineales.

Tabla 8: Principales asociaciones con cada variable objetivo: Pearson frente a Spearman.


Variable	Pearson	Spearman
<i>Con churn_probability</i>		
active_products	-0,88	-0,84
app_logins_frequency	-0,26	-0,28
age	0,21	0,21
satisfaction_score	-0,18	-0,19
nps_score	-0,17	-0,16
<i>Con customer_lifetime_value</i>		
total_tx_volume	0,11	0,98
avg_tx_value	0,34	0,76
tx_satisfaction	0,61	0,56
tx_count	0,16	0,56

El contraste es revelador para el CLV. La correlación de Pearson con `total_tx_volume` es de apenas 0,11, lo que sugeriría una relación débil; sin embargo, el coeficiente de Spearman asciende a 0,98, es decir, una relación monótona prácticamente perfecta. La discrepancia se explica por la extrema asimetría de ambas variables: unos pocos valores muy grandes dominan el cálculo lineal y enmascaran una relación de rango casi determinista. Esta observación tiene una consecuencia metodológica directa: en escala logarítmica, el volumen transaccionado debería ser un predictor muy potente del CLV, y evaluar la asociación únicamente con Pearson habría llevado a descartarlo erróneamente.

En cuanto a las variables categóricas, la asociación medida mediante la *V* de Cramér resulta baja en general, con dos excepciones moderadas: `income_bracket` con `education_level` ($V = 0,38$) y `customer_segment` con `clv_segment` ($V = 0,38$); esta última es esperable, pues ambas describen la intensidad de la relación comercial. El resto de los pares presenta valores iguales o cercanos a cero, lo que indica independencia y descarta redundancia entre las categóricas.

2.2.8 Variable objetivo I: probabilidad de fuga

La Figura 9 muestra la distribución de la fuga y su comportamiento por segmento de cliente, y la Figura 10 la fuga promedio según la tenencia de cada producto.

**Fig. 9:** Distribución de `churn_probability` (izquierda) y su comportamiento por segmento de cliente (derecha).




Fig. 10: Fuga promedio según la tenencia de cada producto. En todos los casos, poseer el producto se asocia con menor fuga.

El hallazgo central del análisis surge al desagregar la fuga por el número de productos activos (Tabla 9). La relación no es simplemente fuerte: es una escalera de paso constante.

Tabla 9: Fuga promedio según el número de productos activos.

Productos activos	Media	Desv. est.	Clientes	Δ media
1	0,40	0,03	19.576	—
2	0,35	0,03	14.653	−0,05
3	0,30	0,03	7.197	−0,05
4	0,25	0,03	4.871	−0,05
5	0,20	0,03	2.426	−0,05

Cada producto adicional reduce la fuga promedio exactamente en 0,0499 en promedio, con una desviación entre los cuatro saltos de apenas 0,00057 y una desviación estándar constante de 0,03 en los cinco grupos. La correlación entre ambas variables es $r = -0,876$, de modo que un único predictor explica el $R^2 = 0,767$ de la varianza de la etiqueta. Una regularidad de esta naturaleza —paso idéntico, dispersión idéntica— no es propia de un fenómeno de comportamiento observado, en el que cabría esperar efectos decrecientes y varianza heterogénea entre grupos. La interpretación más plausible es que `churn_probability` fue generada a partir de `active_products` mediante una regla determinista más un término de ruido de escala reducida. Combinado con el acotamiento del rango documentado antes, ello configura un caso de fuga de información: entrenar un modelo que incluya `active_products` produciría métricas excelentes que no reflejarían capacidad predictiva real sino la recuperación de la fórmula generadora (Kaufman et al., 2012).

Las restantes variables presentan asociaciones débiles pero coherentes con la teoría (Figura 11): a mayor satisfacción y mayor NPS, menor fuga. Las variables categóricas, evaluadas mediante el tamaño de efecto η^2

(Tabla 10), explican una fracción prácticamente nula de la varianza.




Fig. 11: Fuga frente a la satisfacción declarada (izquierda) y al NPS (derecha).

Tabla 10: Tamaño de efecto η^2 de las variables categóricas sobre la fuga.

Variable categórica	η^2
income_bracket	0,0050
location	0,0004
education_level	0,0002
preferred_transaction_type	0,0001
customer_segment	0,0001
acquisition_channel	0,0000

Ninguna categórica supera el 0,5 % de varianza explicada, lo que confirma que el perfil demográfico y el canal de adquisición aportan una señal marginal frente al número de productos.

2.2.9 Variable objetivo II: valor del cliente

El CLV, representado en escala logarítmica (Figura 12), presenta una distribución aproximadamente log-normal y una progresión ordenada a lo largo de los segmentos de valor.




Fig. 12: Distribución de log(1 + CLV) (izquierda) y CLV por segmento de valor en escala logarítmica (derecha).

Tabla 11: CLV mediano por segmento de valor y por segmento de cliente (COP).

clv_segment	CLV mediano	customer_segment	CLV mediano
<i>Bronze</i>	$4,11 \times 10^7$	<i>inactive</i>	$3,15 \times 10^7$
<i>Silver</i>	$9,58 \times 10^7$	<i>occasional</i>	$8,80 \times 10^7$
<i>Gold</i>	$1,91 \times 10^8$	<i>regular</i>	$2,36 \times 10^8$
<i>Platinum</i>	$4,93 \times 10^8$	<i>power</i>	$5,34 \times 10^8$

La progresión es monótona y de gran amplitud en ambas particiones: el CLV mediano se multiplica por doce entre *Bronze* y *Platinum*, y por diecisiete entre los clientes inactivos y los de mayor actividad (Tabla 11). El tamaño de efecto de *clv_segment* sobre el CLV es $\eta^2 = 0,194$, muy superior al de cualquier categórica sobre la fuga.

Resulta notable, en contraste, que el CLV mediano no varíe con el número de productos activos (Figura 13, izquierda): permanece en torno a $1,29 \times 10^8$ para clientes con uno a cuatro productos y solo asciende levemente a $1,38 \times 10^8$ con cinco. Es decir, la variable que casi determina la fuga carece de relación con el valor del cliente. El CLV se explica por la intensidad transaccional —como muestra el panel derecho de la Figura 13 y confirma el coeficiente de Spearman de 0,98 con el volumen— y no por la amplitud de la relación comercial. Ambos objetivos responden, por tanto, a mecanismos distintos, y la Figura 14 lo corrobora: la correlación entre fuga y CLV es prácticamente nula ($r = -0,02$).




Fig. 13: CLV por número de productos activos (izquierda) y frente al volumen total transaccionado (derecha), ambos en escala logarítmica.




Fig. 14: Relación entre las dos variables objetivo. La ausencia de estructura confirma su independencia.

2.2.10 Comportamiento transaccional

La tabla de transacciones cubre del 4 de enero al 29 de diciembre de 2023 y registra actividad para la totalidad de los 48.723 clientes. Su composición por tipo de operación aparece en la Tabla 12.

Tabla 12: Composición de las transacciones por tipo de operación.

Tipo	Cantidad	Participación (%)
<i>Transfer</i>	1.433.963	45,4
<i>Payment</i>	970.548	30,7
<i>Withdrawal</i>	456.577	14,5
<i>Deposit</i>	298.069	9,4
Total	3.159.157	100,0

La auditoría de calidad de esta tabla arroja 102 filas exactamente duplicadas (0,003 %), ningún monto menor o igual a cero, ninguna fecha nula, ningún cliente huérfano sin perfil asociado y ningún cliente sin transacciones; las cinco comprobaciones se ejecutan explícitamente en el cuaderno. Cabe señalar que el signo de la operación reside exclusivamente en el campo type, dado que todos los montos son positivos; calcular flujos netos exigirá aplicar el signo correspondiente según el tipo.

Los montos por tipo de operación (Figura 15) presentan distribuciones similares entre sí en escala logarítmica. La evolución mensual (Figura 16) es estable, sin tendencia ni estacionalidad marcada, y la distribución por día de

la semana (Figura 17) es homogénea, sin la caída de fin de semana que cabría esperar en datos financieros reales —observación coherente con la naturaleza parcialmente sintética del conjunto.




Fig. 15: Distribución del monto por tipo de transacción en escala logarítmica.




Fig. 16: Evolución mensual del número de transacciones y del volumen monetario.




Fig. 17: Transacciones por día de la semana y composición mensual por tipo de operación.

El aporte decisivo de esta tabla es que permite verificar de forma independiente los resúmenes por cliente. Agregando el detalle real por customer_id y comparándolo con cada columna reportada se obtiene la Tabla 13.

Tabla 13: Reconciliación de las columnas reportadas contra el detalle real de transacciones.

Columna reportada	Magnitud real	Coincidencia (%)	Veredicto
tx_count	Número de transacciones	100,0	Confiable
total_tx_volume	Suma de montos	100,0	Confiable
avg_tx_value	Monto promedio	100,0	Confiable
monthly_transaction_count	Número de transacciones	0,1	Descartar
total_transaction_volume	Suma de montos	0,4	Descartar
average_transaction_value	Monto promedio	1,1	Descartar

El resultado es inequívoco y confirma el diagnóstico de la Tabla 4: las tres columnas del primer grupo reproducen exactamente la agregación del detalle transaccional, mientras que sus homólogas del segundo grupo apenas coinciden en un 0,1 a 1,1 % de los casos, porcentaje atribuible a coincidencias fortuitas. La Figura 18 ilustra gráficamente esta correspondencia perfecta para el volumen, junto con la fuga promedio por quintil de actividad transaccional.




Fig. 18: Volumen reportado frente al calculado desde el detalle (izquierda) y fuga promedio por quintil de número de transacciones (derecha).

2.2.11 Decisiones de preprocesamiento derivadas del EDA

Los hallazgos anteriores determinan directamente el tratamiento de los datos previo al modelado, según se resume en la Tabla 14.

Tabla 14: Decisiones de preprocesamiento y hallazgo del EDA que las justifica.

Hallazgo del EDA	Decisión adoptada
Fuga casi determinada por <code>active_products</code> ($R^2 = 0,767$, escalera de paso constante)	Auditar la construcción de la etiqueta; excluir <code>active_products</code> del conjunto de predictores y reportar por separado el desempeño con y sin ella
Columnas transaccionales duplicadas o desalineadas (Tablas 4 y 13)	Eliminar <code>average_transaction_value</code> , <code>total_transaction_volume</code> , <code>avg_daily_transactions</code> y <code>monthly_transaction_count</code> ; conservar las verificadas contra el detalle
<code>credit_utilization_ratio</code> ausente exactamente cuando no hay tarjeta	Imputar cero por tratarse de un <i>no aplica</i> ; la imputación no usa ningún estadístico del conjunto y por tanto no introduce fuga
Faltantes sin mecanismo ni señal en <code>complaint_topics</code> y <code>feature_requests</code>	Descartar ambas columnas; no imputar contenido sin respaldo
Asimetría extrema en variables monetarias; $\rho_{\text{Spearman}} = 0,98$ entre CLV y volumen	No eliminar atípicos; estandarizar dentro del <i>pipeline</i>
<code>satisfaction_score</code> y <code>nps_score</code> con $r = 0,917$	Conservar una sola de las dos en modelos lineales
<code>occupation</code> de alta cardinalidad y $\eta^2 = 0,0008$	Eliminar por cardinalidad sin señal

2.3 Modelos de referencia

Se emplean como referencia los modelos lineales vistos en el curso, que constituyen el punto de partida natural para datos tabulares y ofrecen coeficientes interpretables, condición útil cuando el objetivo incluye entender qué variables explican la fuga. Puesto que la variable objetivo es continua, se desarrollan las dos formulaciones.

2.3.1 Clasificación: regresión logística regularizada

La regresión logística modela la probabilidad de pertenecer a la clase positiva mediante la función logística aplicada a una combinación lineal de las variables:

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b), \quad \sigma(z) = 1 / (1 + e^{-z}). \quad (1)$$

Los parámetros se estiman minimizando la entropía cruzada sobre las n observaciones. Sobre esa función objetivo se añaden los dos esquemas de regularización estudiados. La penalización Ridge (L_2) (Hoerl y Kennard, 1970) reduce la magnitud de los coeficientes de forma continua y reparte el peso entre variables correlacionadas; la penalización Lasso (L_1) (Tibshirani, 1996) sustituye la norma euclídea por la norma L_1 , cuya geometría lleva coeficientes exactamente a cero y produce, por tanto, selección automática de variables:

$$\min_{\mathbf{w}, b} -\sum_i [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] + (1 / 2C) \|\mathbf{w}\|_2^2, \quad (2)$$

$$\min_{\mathbf{w}, b} -\sum_i [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] + (1 / C) \|\mathbf{w}\|_1. \quad (3)$$

En ambas formulaciones C es el inverso de la intensidad de regularización: valores pequeños penalizan con más fuerza. Se exploraron los valores $C \in \{10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 10^2\}$ combinados con las dos penalizaciones mediante búsqueda en rejilla.

2.3.2 Regresión: Ridge y Lasso sobre el objetivo continuo

Puesto que `churn_probability` es continua, la tarea admite tratarse directamente como regresión, sin binarizar. Se emplean los estimadores Ridge y Lasso de `scikit-learn`, que aplican las mismas dos penalizaciones sobre el error cuadrático:

$$\text{Ridge: } \min_{\mathbf{w}, b} \|\mathbf{y} - \mathbf{X}\mathbf{w} - b\|_2^2 + \alpha \|\mathbf{w}\|_2^2, \quad (4)$$

$$\text{Lasso: } \min_{\mathbf{w}, b} (1 / 2n) \|\mathbf{y} - \mathbf{X}\mathbf{w} - b\|_2^2 + \alpha \|\mathbf{w}\|_1. \quad (5)$$

Aquí el hiperparámetro es α , la intensidad de la penalización, con una convención inversa a la de C : valores **grandes** penalizan más. Se exploraron $\alpha \in \{0,01; 0,1; 1; 10; 10^2; 10^3; 10^4; 10^5\}$ para Ridge y $\alpha \in \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}\}$ para Lasso, y se compararon contra mínimos cuadrados ordinarios sin penalización. Las métricas reportadas son el coeficiente de determinación R^2 , la raíz del error cuadrático medio (RMSE) y el error absoluto medio (MAE).

Esta formulación cumple además una función diagnóstica. Como se muestra en la Sección 3.1, el R^2 mide directamente qué fracción de la varianza de la etiqueta reproduce cada conjunto de variables, y por ello detecta la fuga de información con mucha mayor nitidez que el área bajo la curva, que comprime la diferencia al operar sobre la etiqueta ya binarizada.

2.3.3 Referencia no paramétrica: k vecinos más cercanos

Para acotar empíricamente el margen de mejora disponible se incorpora un clasificador de k vecinos más cercanos, que asigna a cada observación la clase mayoritaria entre sus k vecinos en el espacio estandarizado y no impone forma funcional alguna. Si existieran relaciones no lineales o interacciones relevantes entre los predictores, este método debería superar al modelo lineal. Se exploraron $k \in \{10, 25, 50, 100, 200\}$.

2.4 Preparación del conjunto de modelado

Las decisiones de la Sección 2.2 se aplicaron sobre la unión de las dos tablas. Del detalle transaccional se eliminaron 102 filas exactamente duplicadas y se derivaron doce variables de comportamiento —número de operaciones, montos agregados, recencia, días activo, volatilidad del monto, meses con actividad y composición por tipo de operación—, obteniendo una tabla unida de 48.723 filas y 66 columnas.

De ellas se descartaron 17, cada una con evidencia cuantitativa (Tabla 15), resultando un conjunto de 49 columnas. Los 18.263 valores ausentes de `credit_utilization_ratio` se imputaron con cero, decisión respaldada por la correspondencia perfecta con la tenencia de tarjeta. Toda la evidencia de la Tabla 15 se recalcula dentro del cuaderno, de modo que cada criterio de eliminación queda respaldado por una salida de la misma ejecución.

Tabla 15: Variables eliminadas del conjunto de modelado y evidencia que respalda cada decisión.

Columna	Evidencia	Criterio
active_products	$r = -0,8760$; $R^2 = 0,767$ con una sola variable; saltos medios de $-0,0499$ con desviación de $0,00057$	Fuga de información
customer_lifetime_value, clv_segment	$\rho_{\text{Spearman}} = 0,984$ con total_tx_volume	Segunda variable objetivo
average_transaction_value, total_transaction_volume	100 % de los mismos valores con 0 % de coincidencia por fila	Duplicado desalineado
avg_daily_transactions, monthly_transaction_count	$r = 1,000$ con transaction_frequency	Duplicado exacto
first_transaction_date, last_transaction_date	Idéntico número de valores distintos y rango que first_tx y last_tx	Duplicado
nps_score	$r = 0,917$ con satisfaction_score	Colinealidad
occupation	35 niveles, ninguno supera el 3 %; $\eta^2 = 0,0008$	Cardinalidad sin señal
complaint_topics, feature_requests	50,0 % y 33,1 % ausentes, con ausencia aleatoria y correlación de $-0,0007$ y $-0,0066$ con el objetivo	Faltantes sin mecanismo
last_survey_date, first_tx, last_tx	η^2 entre $0,0035$ y $0,0070$	Fechas sin señal
customer_id	Llave única	Identificador

Merece mención una hipótesis que la verificación descartó. Cabía sospechar que active_products fuese la suma de las columnas booleanas de tenencia, en cuyo caso conservarlas habría reintroducido la fuga; la comprobación arrojó una coincidencia de apenas 22,5 % y una correlación de 0,006, por lo que esas columnas son independientes y se conservaron. El experimento de ablación de la Sección 3.1 lo confirma de forma independiente.

2.5 Configuración experimental

La construcción de la etiqueta binaria exige una precaución que conviene explicitar. Binarizar churn_probability por su mediana requiere estimar esa mediana, y una mediana calculada sobre las 48.723 filas haría que la definición de la etiqueta de prueba dependiera de las propias observaciones de prueba. Sería una fuga de información en el diseño experimental, distinta de la fuga por variable diagnosticada en la Sección 2.2.8 pero igualmente invalidante, y tanto más fácil de pasar por alto cuanto que el estadístico en cuestión parece inocuo.

El orden que evita ese problema es el siguiente. Primero se realiza la partición en entrenamiento y prueba, en proporción 80/20 (38.978 y 9.745 clientes) con semilla fija (random_state = 42), **sobre la variable objetivo continua**. Después se estima el umbral de binarización como la mediana de churn_probability **en el conjunto de entrenamiento** (0,353972). Finalmente ese umbral, ya fijo, se aplica a ambos conjuntos. Como la etiqueta no existe en el momento de partir, la partición no puede estratificarse por ella; el balance resultante es de todos modos de 49,99 % y 49,91 % de clase positiva en entrenamiento y prueba, porque el corte es la mediana.

La magnitud de esa fuga potencial se midió explícitamente, en lugar de darse por supuesta. Con la semilla 42, el umbral estimado solo con entrenamiento coincide con el que se habría obtenido sobre el conjunto completo, y ninguna etiqueta de prueba difiere. La razón es que churn_probability toma únicamente 1.977 valores

distintos entre 48.723 clientes —unos 25 clientes por valor—, de modo que la mediana cae sobre un valor repetido y la coincidencia depende del reparto concreto. Repitiendo el procedimiento con otras semillas (Tabla 16) se comprueba que el umbral sí se desplaza y que llegan a cambiar hasta 18 etiquetas de prueba. La coincidencia es, por tanto, un accidente de la partición y no una propiedad del procedimiento, lo que ilustra por qué el orden correcto debe respetarse con independencia de que una semilla particular lo haga indiferente.

Tabla 16: Sensibilidad del umbral de binarización a la semilla de partición. La diferencia se mide contra el umbral estimado sobre el conjunto completo, 0,353972.

Semilla	Umbral en entrenamiento	Diferencia	Etiquetas de prueba que cambian
0	0,354240	$+2,69 \times 10^{-4}$	18
1	0,353858	$-1,14 \times 10^{-4}$	6
7	0,353972	0	0
42	0,353972	0	0
123	0,353858	$-1,14 \times 10^{-4}$	5
2024	0,353843	$-1,29 \times 10^{-4}$	16

El preprocesamiento sigue el mismo criterio. Generar las indicadoras de las variables categóricas sobre la tabla completa —aunque no emplea la etiqueta— haría que las columnas resultantes dependieran de los datos de prueba. Para evitarlo, la codificación *one-hot* (descartando el primer nivel para evitar colinealidad perfecta, e ignorando niveles no vistos) y el escalado estandarizado se encapsulan en un `ColumnTransformer` que vive **dentro** del *pipeline*, de modo que se ajustan únicamente con los datos de entrenamiento de cada partición de la validación cruzada. La codificación eleva el conjunto a 78 variables.

La selección de hiperparámetros se realizó por búsqueda en rejilla con validación cruzada de cinco particiones, estratificada en clasificación y ordinaria en regresión, optimizando el área bajo la curva ROC y el R^2 respectivamente. Como métricas de evaluación se reportan, en clasificación, el AUC, la exactitud, la precisión, la exhaustividad (*recall*) y el F1, complementadas con la matriz de confusión y las curvas ROC y precisión–exhaustividad; y en regresión, el R^2 , el RMSE y el MAE. Los experimentos se ejecutaron en Python 3.13.3 con `scikit-learn` 1.7.2, `numpy` 2.2.6 y `pandas` 2.3.3, con un tiempo total de cómputo de aproximadamente 150 segundos.

3 Resultados

3.1 Cuantificación de la fuga de información

Antes de entrenar el modelo definitivo se midió el efecto de la variable identificada como fuga mediante un experimento de ablación: se entrenaron la misma regresión logística y la misma regresión Ridge sobre distintos subconjuntos de variables (Tabla 17).

Tabla 17: Ablación: desempeño en validación cruzada de cinco particiones según el subconjunto de variables, en las dos formulaciones.

Subconjunto de variables	Número	AUC (clasificación)	R^2 (regresión Ridge)
Todas las variables (incluye active_products)	79	0,9736	0,9211
Sin active_products	78	0,6821	0,1513
Sin active_products ni columnas booleanas	71	0,6821	0,1514
Solo variables transaccionales derivadas	12	0,5016	0,0007
Solo demografía y satisfacción	66	0,6816	0,1507

El resultado es concluyente en ambas formulaciones, pero es la de regresión la que lo expresa con mayor claridad. Incluir active_products eleva el AUC de 0,6821 a 0,9736, una diferencia de 0,2915; y eleva el R^2 de 0,1513 a 0,9211, una diferencia de 0,7698. La segunda cifra admite una lectura directa que la primera no permite: **con esa columna el modelo reproduce el 92 % de la varianza de la etiqueta, y sin ella apenas el 15 %**. Eso no corresponde a capacidad predictiva, sino a la recuperación de la regla que generó la etiqueta, y confirma cuantitativamente el diagnóstico de la Sección 2.2.8. La formulación de clasificación comprime esta diferencia porque el AUC opera sobre la etiqueta ya binarizada y descarta la magnitud del puntaje; de ahí el valor diagnóstico de abordar también la tarea en su forma continua.

La coincidencia exacta entre los escenarios segundo y tercero corrobora además que las columnas booleanas de tenencia no reintroducen la fuga por una vía indirecta, lo que justifica conservarlas. Igualmente revelador es el cuarto escenario: las variables derivadas del detalle transaccional, usadas en solitario, alcanzan un AUC de 0,5016 y un R^2 de 0,0007, ambos indistinguibles del azar. El comportamiento transaccional real de los clientes no guarda relación con la etiqueta de fuga de este conjunto, lo que refuerza la conclusión de que dicha etiqueta fue construida sintéticamente.

3.2 Comparación de los esquemas de regularización en clasificación

La Tabla 18 recoge el desempeño de ambas penalizaciones para los valores de C explorados, junto con el número de variables que cada configuración conserva.

Tabla 18: AUC en validación cruzada según penalización e intensidad de regularización, ordenado de mayor a menor.

Penalización	C	AUC medio	Desv. est.	Variables no nulas
Lasso (L_1)	0,10	0,6824	0,0039	57
Ridge (L_2)	0,01	0,6823	0,0038	78
Lasso (L_1)	1,00	0,6822	0,0041	76
Ridge (L_2)	0,10	0,6822	0,0040	78
Ridge (L_2)	1,00	0,6821	0,0042	78
Lasso (L_1)	100,00	0,6821	0,0042	78
Lasso (L_1)	10,00	0,6821	0,0042	77
Ridge (L_2)	10,00	0,6821	0,0042	78
Ridge (L_2)	100,00	0,6821	0,0042	78
Lasso (L_1)	0,01	0,6820	0,0038	19
Ridge (L_2)	0,001	0,6816	0,0037	78
Lasso (L_1)	0,001	0,6799	0,0036	3




Fig. 19: Desempeño y parsimonia frente a la intensidad de regularización. A la izquierda, AUC en validación cruzada con su desviación entre particiones; a la derecha, número de variables con coeficiente no nulo. Ridge no anula ningún coeficiente en todo el rango, mientras que Lasso reduce el modelo de 78 variables a 3.

Las diferencias entre configuraciones son mínimas: el rango completo abarca 0,0025 puntos, inferior a la desviación entre particiones (0,0039). Esto indica que, tras la limpieza, el conjunto no presenta colinealidad severa que la regularización deba corregir. La búsqueda en rejilla seleccionó Lasso con $C = 0,1$, que conserva 57 de las 78 variables.

El valor de la penalización L_1 no reside, por tanto, en el AUC sino en la parsimonia, y la Tabla 18 permite cuantificar ese intercambio con precisión: Lasso con $C = 0,01$ alcanza 0,6820, apenas cuatro diezmilésimas por debajo del óptimo y muy dentro del ruido entre particiones, empleando **solo 19 variables** en lugar de 57. Si el criterio de selección incorporara la simplicidad del modelo además del desempeño, esa configuración sería preferible. Incluso el modelo de tres variables ($C = 0,001$) conserva un AUC de 0,6799, lo que confirma que la señal está extremadamente concentrada.

Se evaluó asimismo la contribución de las variables transaccionales dentro del modelo seleccionado: su inclusión produce un AUC de 0,6824 frente a 0,6818 sin ellas, una diferencia de 0,0006 muy inferior a la desviación entre particiones. En regresión la diferencia es igualmente despreciable: R^2 de 0,1513 frente a 0,1507. La evidencia confirma que no aportan capacidad predictiva.

3.3 Regresión sobre el objetivo continuo

La búsqueda en rejilla seleccionó $\alpha = 1.000$ para Ridge y $\alpha = 0,0001$ para Lasso, ambos óptimos interiores a la rejilla explorada. La Figura 20 muestra el camino de los coeficientes en función de α y hace visible la diferencia geométrica entre ambas penalizaciones: Ridge encoge los coeficientes de forma continua sin anular ninguno en todo el rango, mientras que Lasso los lleva a cero uno a uno, produciendo selección automática de variables.




Fig. 20: Camino de los coeficientes de la regresión Ridge (izquierda) y Lasso (centro) en función de α , y número de variables con coeficiente no nulo en ambos casos (derecha).

La Tabla 19 recoge el desempeño de los tres modelos de regresión sobre el conjunto de prueba.

Tabla 19: Desempeño de los modelos de regresión sobre el conjunto de prueba ($n = 9.745$).

Modelo	R^2	RMSE	MAE	Variables no nulas
Mínimos cuadrados ordinarios	0,1499	0,0617	0,0507	78
Ridge ($\alpha = 1.000$)	0,1509	0,0617	0,0507	78
Lasso ($\alpha = 0,0001$)	0,1511	0,0617	0,0507	40

El RMSE debe interpretarse contra la desviación típica de la variable objetivo en el conjunto de prueba, 0,0669, que es el error que obtendría un modelo que predijera siempre la media. El modelo lo reduce únicamente en un 7,9 %, magnitud coherente con un R^2 de 0,151. En términos absolutos el error es pequeño —el MAE de 0,0507 sobre un objetivo acotado en $[0,11; 0,50]$ —, pero eso se debe al estrecho rango de la variable y no a un ajuste satisfactorio. Las diferencias entre mínimos cuadrados, Ridge y Lasso son mínimas, lo que reproduce el mismo diagnóstico obtenido en clasificación: tras la depuración no queda colinealidad severa que la regularización deba corregir, y su aporte está en la parsimonia —40 variables frente a 78— y no en el ajuste.




Fig. 21: Diagnóstico de la regresión Lasso sobre el conjunto de prueba: predicción frente a valor real (izquierda), residuos frente a predicción (centro) y distribución de los residuos (derecha). El rango de las predicciones es muy inferior al de los valores reales, comportamiento esperable en un modelo con $R^2 = 0,151$.

El diagnóstico de residuos (Figura 21) no revela patrones sistemáticos: los residuos se distribuyen de forma aproximadamente simétrica en torno a cero y sin estructura frente a la predicción, lo que indica que el modelo lineal no deja sin capturar una relación evidente. El rango comprimido de las predicciones frente al de los valores reales es la manifestación gráfica del bajo R^2 : el modelo distingue tendencias generales pero no reproduce la variabilidad individual.

3.4 Desempeño del modelo de clasificación seleccionado

La Tabla 20 resume el desempeño sobre el conjunto de prueba, que no intervino en ninguna etapa del ajuste: ni en la estimación del umbral, ni en el escalado, ni en la codificación, ni en la selección de hiperparámetros.

Tabla 20: Desempeño del modelo seleccionado (Lasso, $C = 0,1$) sobre el conjunto de prueba ($n = 9.745$).

Métrica	Valor
AUC en validación cruzada	0,6824 $\pm$ 0,0039
AUC en prueba	0,6832
Exhaustividad (<i>recall</i>)	0,6515
Precisión	0,6311
F1	0,6412
Exactitud	0,6360
Variables seleccionadas	57 de 78

El AUC en prueba (0,6832) coincide con el obtenido en validación cruzada (0,6824) dentro del margen de error, lo que indica un modelo estable y sin sobreajuste. Al estar las clases balanceadas, precisión y exhaustividad resultan equilibradas (0,631 y 0,652). La Figura 22 presenta la curva ROC, la curva precisión–exhaustividad y la matriz de confusión.




Fig. 22: Evaluación del modelo seleccionado sobre el conjunto de prueba: curva ROC, curva precisión–exhaustividad y matriz de confusión.

3.5 Referencia no paramétrica

La Tabla 21 recoge el desempeño del clasificador de k vecinos más cercanos.

Tabla 21: AUC en validación cruzada del clasificador de k vecinos más cercanos.

k	AUC medio	Desv. est.
10	0,5956	0,0025
25	0,6234	0,0066
50	0,6400	0,0072
100	0,6549	0,0060
200	0,6645	0,0035

El AUC crece monótonamente con k y el mejor valor explorado, $k = 200$, alcanza 0,6645, **por debajo** de la regresión logística regularizada (0,6824). Que el desempeño mejore al ampliar el vecindario indica que la estructura local es ruido y no señal, y que el método converge hacia un comportamiento cada vez más suave. Que un clasificador sin forma funcional impuesta no supere al modelo lineal sugiere que queda poca estructura no lineal o de interacción por capturar con estas variables. Este resultado sustituye por una medición lo que de otro modo sería una conjetura sobre el margen de mejora disponible.

3.6 Variables que sostienen el modelo

Los coeficientes, expresados en escala estandarizada y por tanto comparables entre sí, muestran una concentración notable de la señal (Figura 23).




Fig. 23: Coeficientes de mayor magnitud en escala estandarizada: regresión logística sobre la etiqueta binarizada (izquierda) y regresión Lasso sobre el objetivo continuo (derecha). Ambas formulaciones señalan las mismas tres variables, en el mismo orden y con los mismos signos.

Tabla 22: Coeficientes de las tres variables dominantes en las dos formulaciones, en escala estandarizada.

Variable	Logística (clasificación)	Lasso (regresión)
app_logins_frequency	-0,4701	-0,0174
age	+0,4123	+0,0157
satisfaction_score	-0,3861	-0,0128

Tres variables concentran prácticamente toda la capacidad predictiva: la frecuencia de acceso a la aplicación (-0,4701), la edad (+0,4123) y la satisfacción declarada (-0,3861). Las restantes presentan coeficientes de magnitud considerablemente menor. Los signos son coherentes con la teoría de retención: mayor uso del canal digital y mayor satisfacción se asocian con menor riesgo de fuga, mientras que la edad se asocia positivamente con él.

La concordancia entre las dos formulaciones constituye un argumento de robustez. La regresión Lasso sobre el objetivo continuo —un modelo distinto, ajustado sobre una variable distinta y con una función de pérdida distinta— señala exactamente las mismas tres variables, en el mismo orden y con los mismos signos. La lectura no es, por tanto, un artefacto de haber binarizado la etiqueta. Las magnitudes no son directamente comparables entre columnas de la Tabla 22, porque la logística opera sobre el *logit* y la regresión sobre la escala original del puntaje; lo comparable es el orden relativo y el signo.

4 Conclusiones

Este trabajo abordó la caracterización, la auditoría de calidad y el modelado base para predecir la fuga de clientes sobre un conjunto público de una empresa fintech colombiana. El análisis exploratorio describió las 54 variables de los 48.723 clientes y los 3,16 millones de transacciones asociadas, y verificó que ambas tablas son mutuamente consistentes: sin clientes huérfanos, sin montos inválidos, sin fechas nulas y con cobertura transaccional completa.

La auditoría reveló tres condiciones que habrían comprometido cualquier resultado obtenido sobre los datos crudos. La principal es la relación entre *churn_probability* y *active_products*: una escalera de paso

constante que explica el 76,7 % de la varianza de la etiqueta y que, junto con el truncamiento artificial del rango, indica que la variable objetivo fue construida a partir de un predictor disponible. La segunda es la presencia de columnas transaccionales duplicadas y desalineadas, cuya naturaleza solo se hizo evidente al comparar las distribuciones como conjuntos y al reconciliarlas contra el detalle real. La tercera es el carácter estructural de los valores faltantes de `credit_utilization_ratio`. Estos hallazgos se tradujeron en la eliminación documentada de 17 variables y en un conjunto depurado de 49 columnas.

El experimento de ablación cuantificó el impacto de la fuga en las dos formulaciones, y es la de regresión la que lo hace de forma más elocuente: incluir `active_products` eleva el R^2 de 0,1513 a 0,9211 y el AUC de 0,6821 a 0,9736. Que una sola columna reproduzca el 92 % de la varianza de la etiqueta no admite lectura como capacidad predictiva. Se optó por excluirla, que es el único escenario metodológicamente defendible.

Sobre el conjunto depurado, la regresión logística con penalización L_1 alcanza un AUC de 0,6832 en el conjunto de prueba, con exhaustividad de 0,6515 y precisión de 0,6311, seleccionando 57 de las 78 variables disponibles; una configuración más penalizada ($C = 0,01$) alcanza un AUC prácticamente idéntico con solo 19 variables, de modo que la parsimonia se obtiene a un coste despreciable. Sobre el objetivo continuo, la regresión Lasso alcanza $R^2 = 0,1511$ con RMSE de 0,0617, frente a una desviación típica del objetivo de 0,0669: una reducción del error de apenas el 7,9 %. El desempeño se concentra en tres predictores —frecuencia de uso de la aplicación, edad y satisfacción declarada—, identificados de forma concordante por las dos formulaciones, mientras que el comportamiento transaccional no aporta capacidad predictiva alguna, como confirman tanto las correlaciones (todas por debajo de 0,03 en valor absoluto) como el AUC de 0,5016 y el R^2 de 0,0007 que alcanzan esas variables en solitario.

Sobre el margen de mejora disponible, este trabajo aporta una medición en lugar de una conjetura. Un clasificador de k vecinos más cercanos, que no impone forma funcional alguna y por tanto podría capturar relaciones no lineales e interacciones, alcanza en el mejor caso un AUC de 0,6645, inferior al del modelo lineal. La implicación es que el margen para el modelo propio del proyecto final es estrecho: la suma de las contribuciones individuales de los predictores restantes acota ese margen, y un incremento sustancial del AUC solo sería alcanzable reintroduciendo la variable que produce la fuga, lo que invalidaría el resultado. Este resultado negativo es, en sí mismo, un hallazgo útil para orientar la siguiente fase.

El estudio presenta limitaciones que conviene declarar. El análisis se apoya en un único conjunto cuyos indicios de generación sintética —rangos truncados, ausencia de estacionalidad semanal, paso constante en la escalera de fuga e independencia respecto del comportamiento transaccional— limitan la validez externa de las conclusiones sustantivas sobre comportamiento financiero, aunque no afectan la validez del procedimiento de auditoría ni del modelado. Asimismo, no fue posible confirmar con la fuente cómo se construyó la etiqueta, por lo que la fuga de información se sostiene como la hipótesis más plausible y no como un hecho verificado.

Declaraciones

- **Disponibilidad de datos:** el conjunto es público y está disponible en Mendeley Data, <https://data.mendeley.com/datasets/mhb4zn3258/1> (DOI: 10.17632/mhb4zn3258.1), bajo licencia Creative Commons Attribution 4.0 (Muñoz Guerrero et al., 2025).
- **Disponibilidad de código y reproducibilidad:** el código completo está disponible en https://github.com/RubenEsg/Machine_learning. El cuaderno se publica **ejecutado de principio a fin**, con todas sus salidas y su numeración de ejecución; la ruta de los datos se resuelve de forma relativa, de modo

que no depende de la máquina; y una sección final deja constancia del entorno (Python 3.13.3, numpy 2.2.6, pandas 2.3.3, scikit-learn 1.7.2, semilla 42) y del tiempo total de cómputo. Cada cifra de este manuscrito corresponde a una salida concreta de esa ejecución.

- **Contribución de los autores:** los tres autores participaron conjuntamente en el diseño del análisis, la implementación del cuaderno, la interpretación de los resultados y la redacción del manuscrito. Todos revisaron y aprobaron la versión final.
- **Conflicto de intereses:** los autores declaran no tener conflictos de interés.

Referencias bibliográficas

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, páginas 785–794.
- Gupta, S., Hanssens, D., Hardie, B., Kahn, W., Kumar, V., Lin, N., Ravishanker, N. y Sriram, S. (2006). Modeling customer lifetime value. *Journal of Service Research*, 9(2):139–155.
- Hoerl, A. E. y Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67.
- Kaufman, S., Rosset, S., Perlich, C. y Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):1–21.
- Little, R. J. A. y Rubin, D. B. (2019). *Statistical Analysis with Missing Data*. Wiley, Hoboken, NJ, 3.^a edición.
- Muñoz Guerrero, L. E., Ceballos, Y. F. y Trejos Rojas, L. D. (2025). COFINFAD: Colombian Fintech Financial Analytics Dataset. Mendeley Data, V1. DOI: 10.17632/mhb4zn3258.1.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Tibshirani, R. (1996). Regression shrinkage and selection via the Lasso. *Journal of the Royal Statistical Society: Series B*, 58(1):267–288.
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley, Reading, MA.
- Verbeke, W., Dejaeger, K., Martens, D., Hur, J. y Baesens, B. (2012). New insights into churn prediction in the telecommunication sector: A profit driven data mining approach. *European Journal of Operational Research*, 218(1):211–229.
- Wirth, R. y Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, páginas 29–39.