

Fuga de clientes en una fintech colombiana: modelos, optimización y evaluación

Sustentación del Entregable 3 · Machine Learning · Pregrado en Ciencia de Datos · Universidad del Norte

Martínez Pulido, Valerie · Basto Martínez, Abrahan · Esguerra Fernández, Rubén

Octubre de 2026

48.723

clientes · 3,16 M de transacciones


140 + 20

corridas con validación anidada 5×3

46 h

de cómputo registradas en una tabla maestra

El problema y los datos: un flujo que parte antes de mirar el objetivo



48.723

clientes × 54 variables; 3,16 M de transacciones de 2023

80 / 20

38.978 clientes de entrenamiento y 9.745 de prueba; la prueba no se toca hasta el final

48 → 78



predictores tras la depuración → columnas tras escalar y codificar

24,6 %

de clientes de riesgo alto con la etiqueta del percentil 75

- **Dos tareas:** clasificación del cuarto de clientes de mayor riesgo (AUC como métrica principal) y regresión de churn_probability (RMSE).
- **Corrección de la Entrega 1:** la partición va antes de cualquier estadístico del objetivo y el código la impone (src/datos.py); el umbral de la mediana de la Entrega 2 se filtraba desde el conjunto completo.
- **Depuración con evidencia:** 14 columnas fuera (identificador, duplicados exactos y desalineados, colinealidad, faltantes sin señal); el único faltante que queda (credit_utilization_ratio) es un «no aplica» y se imputa con cero.

Hallazgo 1: la probabilidad de fuga es un puntaje generado desde active_products



$$r = -0,876$$

correlación con active_products; esa sola variable explica el 76,8 % de la varianza

$$0,999$$

R^2 de un modelo que sí conoce active_products: recupera la fórmula, no predice la fuga

Página 01 del libro: distribución de churn_probability (entrenamiento) y su media por número de productos activos.

Decisión: active_products se excluye como predictor

Con ella el problema sería recuperar la regla con la que se construyó la etiqueta. Excluirla deja el problema con su dificultad real, y el resto de variables de tenencia de productos no la reconstruyen ($r = 0,006$).

La etiqueta de riesgo alto es el cuarto superior (umbral 0,3927, estimado solo con entrenamiento). La comparación con la Entrega 2 usa la mediana (0,3540) para que las cifras sean comparables.


Consecuencia: un techo de información medible

Un oráculo que conoce active_products, promediado sobre su distribución, da el mejor pronóstico posible sin ella:

0,7223 de AUC (etiqueta de la mediana) y 0,2197 de R^2 .

La Entrega 2 cubría el 82 % de la discriminación alcanzable y el 69 % del R^2 ; los mejores modelos de esta entrega llegan al 98 %.

EDA: la señal está en cuatro variables y no es lineal



Página 01: media de churn_probabilidad (entrenamiento) por valor de cada variable. ρ de Spearman: $-0,279$, $+0,210$, $-0,190$ y $-0,164$.

Tres cohortes de edad

La edad toma solo 6 valores (29, 30, 44, 45, 59 y 60) con unos 8.120 clientes cada uno, y el archivo está ordenado por esos bloques: el riesgo alto va del 8 % al 46 % según el bloque. Por eso la partición es aleatoria y las pruebas de residuos respetan el orden del archivo.


Las transacciones no aportan

Las 12 variables derivadas del detalle transaccional tienen $|p| \leq 0,018$ con el objetivo. Las dos satisfacciones se parecen ($\rho = 0,83$); la edad y el uso de la aplicación aportan información propia.

Corrección del CLV (Entrega 1)

El CLV no varía con el número de productos activos (ρ de Spearman = $-0,0013$; mediana entre 127,9 y 134,5 millones). Lo ordenan clv_segment (40,9 $\rightarrow$ 492,7 M) y la intensidad transaccional ($\rho = 0,984$). Fuga y valor responden a mecanismos distintos.

Diseño experimental: 140 corridas, todas con validación cruzada anidada



140

7 × 4 × 4 + 7 × 4 corridas de la guía (136 + 4 que no aplican)

+ 20

corridas de la EBM, el modelo nuevo, con las mismas reglas

30–48

evaluaciones por búsqueda, iguales para los cuatro métodos

Semilla única 42 · versiones exactas en requirements.txt · código congelado con huella SHA-256 · 72 pruebas automáticas · multi-fidelidad: Random Forest 100 → 300 árboles, EBM 2 → 8 bolsas (validada en cómputo)

1 Grid Search

Recorre la rejilla explícita completa. Referencia exhaustiva; paraleliza configuraciones × pliegues.

2 Random Search

Muestrea el espacio tipado (log-uniforme, uniforme, enteros). Cubre mejor cada dimensión cuando pocos hiperparámetros importan.

3 Bayesiana (Optuna, TPE)

Sustituto: dos densidades, $\ell(x)$ del 10 % mejor y $g(x)$ del resto. Adquisición: máximo de $\ell(x)/g(x)$, equivalente a la mejora esperada. 10 ensayos aleatorios de arranque.

4 Genética (DEAP)

Torneo de 3 (invariante a la escala del fitness), cruce uniforme (0,5 por gen, prob. 0,6), mutación gaussiana $\sigma = 0,15$ (prob. 0,3), elitismo, población $\max(4, \min(\text{presupuesto}/4, 12))$; diversidad registrada por generación.

Resultados de las 140 corridas: los árboles encabezan y el balanceo no mejora el AUC

AUC media del bucle externo (5 pliegues)

XGBoost	0.8319	0.8310	0.8314	0.8323	0.8317	0.8288	0.8312	0.8297	0.8308	0.8294	0.8302	0.8288	0.8309	0.8303	0.8312	0.8332
Árbol de decisión	0.8307	0.8327	0.8312	0.8321	0.8269	0.8273	0.8262	0.8273	0.8253	0.8257	0.8259	0.8259	0.8329	0.8332	0.8301	0.8321
Random Forest	0.8317	0.8313	0.8322	0.8326	0.8282	0.8288	0.8288	0.8285	0.8282	0.8276	0.8289	0.8293	0.8314	0.8300	0.8296	0.8299
EBM	0.8285	0.8289	0.8289	0.8291	0.8278	0.8284	0.8279	0.8282	0.8280	0.8289	0.8283	0.8286	0.8292	0.8276	0.8287	0.8281
k-NN	0.7831	0.7740	0.7831	0.7836	0.7681	0.7539	0.7674	0.7681	0.7748	0.7580	0.7745	0.7748				
Regresión logística	0.7642	0.7642	0.7643	0.7643	0.7633	0.7629	0.7632	0.7632	0.7632	0.7629	0.7630	0.7631	0.7643	0.7643	0.7644	0.7644
SVM lineal	0.7639	0.7639	0.7639	0.7639	0.7626	0.7626	0.7627	0.7627	0.7625	0.7624	0.7625	0.7624	0.7641	0.7641	0.7641	0.7641
Naive Bayes	0.6722	0.6711	0.6720	0.6722	0.6063	0.6047	0.6061	0.6063	0.6039	0.6024	0.6037	0.6039	0.6722	0.6711	0.6720	0.6722
	Sin balanceo Grid	Sin balanceo Random	Sin balanceo Bayesiana (TPE)	Sin balanceo Genética	SMOTE Grid	SMOTE Random	SMOTE Bayesiana (TPE)	SMOTE Genética	ADASYN Grid	ADASYN Random	ADASYN Bayesiana (TPE)	ADASYN Genética	class_weight Grid	class_weight Random	class_weight Bayesiana (TPE)	class_weight Genética

0,8332

AUC externa del mejor clasificador: XGBoost (class_weight, genética); árbol 0,8332, Random Forest 0,8326, EBM 0,8292

0,0590

RMSE externo del mejor regresor: XGBoost (bayesiana); EBM 0,0590, Random Forest 0,0592; los lineales 0,0618

Página 03: AUC media del bucle externo de las 112 corridas de clasificación (filas: modelos; columnas: balanceo × optimizador).

Tres grupos claros

Árboles 0,829–0,833 · k-NN 0,784 · lineales 0,764 · Naive Bayes 0,672. La desviación entre pliegues (0,002–0,012) es del orden de las diferencias entre los árboles: se contrastan formalmente en la página 09.


El balanceo no mejora la discriminación

class_weight: de –0,0012 a +0,0009 de AUC. SMOTE y ADASYN lo empeoran en casi todos (Friedman $p < 10^{-10}$; Naive Bayes –0,066). Solo mueven el recall con umbral 0,5: XGBoost pasa de 0,000 a 0,987.

Coste

26,9 h las 140 corridas (Random Forest 10,2 h, k-NN 8,1 h, XGBoost 4,2 h); las 20 de la EBM, 19,5 h, 3,7 veces más lentas con sobremuestreo y sin ganancia.

Optimizadores: la bayesiana aprovecha mejor cada evaluación; la métrica final no los separa



$$p < 10^{-7}$$

Friedman sobre el área bajo el arrepentimiento: la bayesiana es la más eficiente por evaluación en las dos tareas

10,3 vs 14,2

evaluaciones para cerrar el 95 % de la brecha: bayesiana frente a Grid (clasificación)

1,7×

más tiempo por evaluación de la bayesiana y la genética: son secuenciales y solo paralelizan los 3 pliegues

Página 04: curvas anytime (arriba; sombreado = cuartiles entre búsquedas) y diagramas de diferencia crítica de Nemenyi sobre la métrica externa (abajo).

- **Métrica final:** genética (rango 1,93), Grid (2,22) y bayesiana (2,63) empatan; Random queda por debajo de Grid en el 74 % de los bloques (−0,0019 de AUC, Wilcoxon $p = 0,004$). En regresión no hay diferencias ($p = 0,815$).
- **Genética:** diversidad de 0,274 a 0,078 en 6–7 generaciones, sin colapsar; mejor rango final en clasificación, menos eficiente que la bayesiana por evaluación (Nemenyi $p = 0,001$).
- **Optimismo de selección −0,001:** la validación interna subestima la externa; la métrica reportada es siempre la del bucle externo.




Cómputo: cada decisión de eficiencia se sostiene con una medición

Modelo	Versión estándar	Versión optimizada	Resultado medido
XGBoost	exact (CPU)	hist (CPU, 6 hilos)	5,76 s → 0,82 s por ajuste (7,0×), mismo AUC; 1 hilo → 6 hilos: 2,8×
XGBoost	hist en CPU	hist en GPU (RTX 3050)	0,82 s → 0,86 s: la GPU no acelera con 39.000 filas y árboles pequeños
XGBoost	500 árboles fijos	early stopping (paciencia 50)	se detiene en 153 árboles: 2,72 s → 1,41 s y AUC 0,8263 → 0,8289
k-NN (78 var.)	fuerza bruta, 8,0 s	KD-Tree / Ball Tree / FAISS	24,1 s / 24,3 s / 12,0 s: en 78 dimensiones ningún índice gana; HNSW solo acelera con euclídea y k pequeño (2,7×)
k-NN	78 variables	4 variables con señal + KD-Tree	consulta 8,0 s → 1,85 s y AUC 0,787 → 0,821: menos columnas, más rápido y mejor
SVM	SVC con núcleo RBF	LinearSVC primal (L2)	43 s frente a 0,61 s por ajuste (70×, extrapolado a n); las 16 corridas pasarían de 0,8 h a 17 h
Ridge / Lasso / logística	SAGA, SGD-L1, SAGA	cholesky, coordenadas, liblinear	15,1 s → 0,08 s; 0,88 s → 0,22 s; 19,4 s → 1,27 s, con la misma métrica
Random Forest / EBM	búsqueda con fidelidad alta	100 árboles / 2 bolsas en la búsqueda	ρ de Spearman 0,94 y 0,83 entre fidelidades, misma ganadora, 65 % menos tiempo; RF con 6 hilos: 4,2×

Página 05: tabla estándar frente a optimizado (§4 de la guía). Medido con los hiperparámetros finales en un equipo de 6 núcleos y RTX 3050, sin otra carga. Perfil: el 79 % del tiempo de una validación cruzada es el ajuste del modelo.

Paralelismo: dentro de cada corrida (pliegues × configuraciones) ocupaba los 6 núcleos (2,6× frente a la serie); entre modelos solo 1,5×. Las 26,9 h se repartirían casi linealmente con Dask o Ray.

Evaluación: la validación anidada predice la prueba; el umbral de 0,5 engaña





$\rho = 0,997$

entre el AUC de la validación anidada y el de prueba (124 corridas); diferencia media +0,0016

51 % · lift 2,05

de la fuga capturada contactando al 25 % de mayor riesgo según la EBM (precisión 0,504)



$ECE \leq 0,010$

tras la recalibración isotónica (antes, de 0,027 a 0,682); el AUC no cambia porque es monótona

Página 06: curvas ROC en prueba, diagramas de confiabilidad antes y después de la recalibración isotónica, y AUC externo frente a AUC de prueba.

- **AUC de prueba:** EBM 0,8289, XGBoost 0,8283, Random Forest 0,8260, árbol 0,8243; con umbral 0,5 el recall va de 0,000 (k-NN) a 1,000 (árbol): el umbral se fija aparte, por capacidad de la campaña.
- **Regresión:** XGBoost RMSE 0,0592 [0,0584; 0,0600] y R^2 0,218; entrenamiento 0,234 → validación 0,228 → prueba 0,218. Residuos: White no rechaza en ningún modelo; Ljung-Box y BDS detectan dependencia solo en los lineales y k-NN; normalidad rechazada en todos.
- **Semillas:** desviación del AUC de prueba entre semillas de 0,0000 a 0,0010; la diferencia EBM–XGBoost (0,0006) es de ese orden.

El modelo nuevo: la EBM supera a la Entrega 2 y empatata con XGBoost siendo legible

0,6832 → 0,7187

AUC en prueba (etiqueta de la mediana):
logística L1 de la Entrega 2 → EBM. DeLong z =
9,02, $p < 10^{-18}$; BCa [+0,0281; +0,0434]


0,1511 → 0,2159

R^2 en prueba: Lasso de la Entrega 2 → EBM.
Diebold-Mariano con HLN 13,33, $p < 10^{-39}$;
bootstrap estacionario $p < 0,001$

$p = 0,196 \cdot 0,074$ 98 %

frente a XGBoost, el mejor modelo de clase:
-0,0019 de AUC y -0,0017 de R^2 , sin
diferencia significativa

del techo de información alcanzable sin
active_products (0,7223 de AUC y 0,2197
de R^2); la Entrega 2 estaba al 82 % y 69 %



Página 08: funciones de forma de la EBM (naranja) frente al efecto lineal de la logística L1 de la Entrega 2 (azul), en la escala del logit, para las cuatro variables con señal.



Por qué falló la Entrega 2

La edad va de -0,73 a +0,85 en el logit y no es monótona; el uso de la aplicación se aplana; la L1 anuló base_satisfaction. Una EBM sin interacciones da 0,7185 ($p = 0,910$ frente a la completa): faltaba flexibilidad por variable.

Qué es la EBM

GA²M: $g(E[y]) = \beta_0 + \sum f_j(x_j) + \sum f_{ij}(x_i, x_j)$. Cada curva se aprende por boosting cíclico de árboles pequeños y se promedia en 8 bolsas. Tan legible como una logística, tan flexible como el boosting. No está en el curso.

SHAP y la EBM cuentan la misma historia; los finalistas no se distinguen



Página 07: SHAP (TreeExplainer, exacto) de XGBoost en prueba. Página 09: diagramas de diferencia crítica de Nemenyi (5 pliegues y 60 bloques); barras = modelos que no difieren al 5 %.

SHAP, LIME y la EBM

Cuatro variables reúnen el 97 % del $|\text{SHAP}|$. LIME coincide con SHAP en 3/5 y 2/5 variables (estabilidad 58 %, R^2 local 0,41–0,44): aproximación local. La EBM da la misma forma sin explicador.

Clasificación

Friedman $p < 10^{-4}$ (Iman-Davenport $p < 10^{-13}$). Finalistas: XGBoost, Random Forest, árbol y EBM; DeLong por pares con Holm: ninguna diferencia sobrevive (0,0006–0,0046 de AUC; intervalos BCa de $\pm 0,009$).

Regresión

Model Confidence Set al 90 %: solo XGBoost (EBM $p = 0,072$, RF $p = 0,005$). SPA frente a XGBoost $p = 0,974$; frente al Lasso $p < 0,001$. Diebold-Mariano RF–XGBoost $p = 0,003$ (d de Cohen 0,03: pequeña pero estable).

Conclusiones

1

Los datos fijan el techo

churn_probability es un puntaje generado desde active_products; sin ella, el máximo alcanzable es 0,722 de AUC (mediana) y 0,220 de R^2 . Parte del bajo desempeño anterior era inevitable.

2

Los árboles ganan y no se distinguen entre sí

XGBoost, árbol, Random Forest y EBM entre 0,829 y 0,833 de AUC; Friedman, Nemenyi y DeLong con Holm no los separan. En regresión el MCS deja a XGBoost, por décimas de milésima.

3

El modelo nuevo cumple la exigencia

La EBM supera a la Entrega 2: +0,0355 de AUC ($p < 10^{-18}$) y +0,0648 de R^2 ($p < 10^{-39}$); empata con XGBoost ($p = 0,196$ y $0,074$) y explica cada variable con una curva.

4

La bayesiana es la más eficiente por evaluación

Friedman sobre el área de arrepentimiento $p < 10^{-7}$; la métrica final empata (Random por debajo). En reloj, las secuenciales tardan 1,7× más en 6 núcleos. La validación anidada predijo la prueba ($p = 0,997$).

5

Balanceo y calibración

class_weight no cambia el AUC y el sobremuestreo lo empeora: el balanceo elige el punto de operación. La isotónica deja el ECE entre 0,003 y 0,010 sin tocar el orden.

6

Cómputo con mediciones; límites

hist 7× más rápido, la GPU no acelera, 4 variables para k-NN, SVM lineal, multi-fidelidad validada. COFINFAD es sintético y la etiqueta es un puntaje: validar en el tiempo con datos reales.

Libro, código, cuadernos ejecutados y resultados: github.com/RubenEsg/predicci-n-de-fuga-de-clientes-en-fintech